



UNIVERSIDADE FEDERAL DO CEARÁ

CAMPUS QUIXADÁ

Detecção de Falhas em Drones com Base em Sinais de Vibração Utilizando TinyML

Estudante: André Alves de Freitas
Curso: Engenharia de Computação

Entregável 3 - Final



Motivação

- Crescimento do uso de drones em diversos setores: segurança, agricultura, monitoramento, mapeamento
- Sistemas aéreos exigem alta confiabilidade, pequenas irregularidades comprometem a estabilidade do voo
- Vibração como indicador não intrusivo de falhas mecânicas

Motivação

- A grande maioria dos trabalhos com ML dependem de telemetria enviada a processamento externo (Adaika et al. 2025)
- Isso gera atraso na detecção e dependência de transmissão contínua de dados
- TinyML viabiliza inferência local, com baixa latência e baixo custo computacional

Fluxo Metodológico



Visão geral do Dataset

- Dataset autoral (inspirado em referência pública)
Al-Haddad, Luttfi A. (2025). Dados de vibração multiaxial para diagnóstico de falhas em pás de veículos aéreos não tripulados multirrotores. figshare. Conjunto de dados. <https://doi.org/10.6084/m9.figshare.28765640.v1>
- Tipo de dado: séries temporais de vibração (acelerômetro triaxial MPU-6050)
- Três atributos principais (eixos X, Y e Z) medidos em m/s^2
- Coleta: bancada controlada, 15000 amostras brutas por condição

Classes do Dataset

- Normal
- Anômalo nível 1
- Anômalo nível 2

Implementação do Modelo

- Modelo de classificação com CNN 1D

https://colab.research.google.com/drive/1IZiZG0CSGYFVTtZQ3nSK9eL3_bvZ0bjL?usp=sharing

Reprodutibilidade / GitHub

- Link github

<https://github.com/AndreAlves-18/tinymml-drone-vibration-detector.git>

Conclusão e Próximos Passos

- CNN 1D compacta implementada para classificação de 3 classes de vibração
- Acurácia de 100% no teste, $F1 = 1,00$, perda = 0,0091
- 6.467 parâmetros treináveis — arquitetura enxuta para TinyML
- Próximos passos: Adicionar mais classes

Obrigado!